

Plataforma de Monitoramento da Etapa de Mosturação na Fabricação de Cerveja Artesanal

Haimon Cugler Vieira¹, João Alexandre Pinto Camargo², Jocieli Pontes Domingues da
Silva³, Kevin da Silva Oliveira⁴

¹Faculdade de Tecnologia do Estado de São Paulo

²Faculdade de Tecnologia do Estado de São Paulo

³Faculdade de Tecnologia do Estado de São Paulo

⁴Faculdade de Tecnologia do Estado de São Paulo

*haimon.vieira@aluno.cps.sp.gov.br, joao.camargo10@aluno.cps.sp.gov.br,
kevin.oliveira6@aluno.cps.sp.gov.br, jocieli.domingues@aluno.cps.sp.gov.br*

1 Introdução

O setor cervejeiro artesanal tem experimentado crescimento consistente nos últimos anos, consolidando-se como um dos segmentos mais dinâmicos da indústria de bebidas. De acordo com o *Anuário da Cerveja 2025: Ano de Referência 2024*, o Brasil registrou 1949 cervejarias em funcionamento, com crescimento de 5,5% em relação ao ano anterior, sendo a região Sudeste responsável pela maior concentração desses estabelecimentos [1]. Esse cenário evidencia a expansão do mercado e o fortalecimento das micro e pequenas cervejarias artesanais, que vêm desempenhando papel relevante na inovação e diversificação da produção nacional.

No contexto regional, o Vale do Ribeira tem acompanhado esse crescimento por meio da consolidação da EXPOBEER Vale do Ribeira, evento que evoluiu do tradicional Encontro de Cervejeiros e passou a integrar ações voltadas à capacitação técnica, rodadas de negócios e valorização da produção local [2]. A profissionalização do setor regional reforça a necessidade de aprimoramento tecnológico nos processos produtivos, especialmente no que se refere ao controle das etapas críticas da fabricação.

Contudo, a produção em pequena escala pode apresentar limitações de automação e de registro das variáveis do processo. Essa dificuldade é particularmente relevante na mosturação, etapa em que o acompanhamento da temperatura e do tempo precisa ser relacionado ao avanço da conversão do amido, e não apenas ao cumprimento de uma programação térmica.

A mosturação consiste no aquecimento controlado da mistura de água e malte para favorecer a ação das enzimas responsáveis pela degradação do amido e pela formação de açúcares fermentescíveis e dextrinas. Temperatura, tempo e pH influenciam essa atividade enzimática e, consequentemente, as características do mosto produzido [3]. O monitoramento da temperatura indica se as condições programadas foram mantidas, mas não determina, isoladamente, se ainda existe amido residual na amostra.

O teste de iodo é utilizado para acompanhar essa conversão. Nele, uma alíquota do mosto entra em contato com uma solução contendo iodo, produzindo tons escuros, violetas ou avermelhados quando ainda existem estruturas amiláceas capazes de reagir com o composto e uma coloração amarela quando essas estruturas já não são detectadas pelo teste [3]. Almeida e Ribeiro aplicaram esse procedimento no início e ao final de uma mosturação, interpretando visualmente a mudança de coloração [4].

Quando realizada manualmente, essa interpretação depende da comparação visual feita pelo operador e pode ser dificultada por gradações intermediárias, iluminação, reflexos e características da própria amostra. Além disso, se a imagem e o resultado do teste não forem registrados juntamente com data, hora, temperatura e tempo de mosturação, torna-se difícil revisar a decisão tomada e comparar leituras entre diferentes lotes. O problema investigado neste trabalho é, portanto, como tornar a leitura do teste de iodo mais padronizada e rastreável, sem apresentar a automação proposta como substituta de uma análise laboratorial quantitativa.

Alinhado aos **Objetivos de Desenvolvimento Sustentável (ODS)** da Organização das Nações Unidas, este trabalho propõe uma **plataforma de monitoramento da etapa de mosturação na fabricação de cerveja artesanal**. A plataforma deverá utilizar visão computacional com Python e OpenCV para analisar imagens do teste de iodo e relacionar a classificação obtida aos registros de temperatura e tempo. A iniciativa pode contribuir para o ODS 9 (Indústria, Inovação e Infraestrutura), ao propor uma alternativa de automação acessível para pequenos produtores, e pode apoiar o ODS 12 (Consumo e Produção Responsáveis), caso estudos posteriores demonstrem redução de desperdícios ou melhoria de rendimento. Nesta versão, essas capacidades constituem especificações a serem validadas, sem resultados experimentais de impacto ambiental ou produtivo.

2 Objetivos

O presente trabalho tem como objetivo geral desenvolver uma **Plataforma de Monitoramento para Fabricação de Cerveja Artesanal**, utilizando visão computacional com Python e OpenCV para automatizar o teste de iodo. A plataforma visa realizar a aquisição, supervisão e análise de dados das etapas críticas do processo produtivo, com ênfase na atividade enzimática durante a mosturação, melhorando a eficiência operacional, a rastreabilidade e a qualidade final da bebida.

Os objetivos específicos deste trabalho são:

- Desenvolver um sistema automatizado para a realização do **teste de iodo** utilizando **visão computacional com Python e OpenCV**, capaz de detectar a presença de amido residual no mosto. O desempenho será avaliado pela acurácia das classificações conclusivas, tendo como meta valor igual ou superior a 50%.
- Implementar um algoritmo de processamento de imagem para **análise da cor da reação de iodo**, diferenciando automaticamente as cores violeta (presença de amido), intermediária (conversão parcial) e amarela (ausência de amido), e integrar essa análise ao monitoramento de temperatura. O tempo de resposta, medido entre o envio da imagem para análise e a exibição do resultado na interface, deverá apresentar média de até 2 segundos e percentil 60 de até 10 segundos no hardware adotado.
- Desenvolver uma interface de usuário que permita a **visualização e análise dos dados** coletados, incluindo gráficos de temperatura, resultados do teste de iodo e alertas para ajustes necessários no processo de mosturação. Como indicadores, será verificado o registro de 100% das leituras válidas com data e hora, temperatura, classificação e tempo de resposta, bem como a emissão de alerta nos casos previstos pelas regras do sistema.

- Validar a plataforma desenvolvida por meio de **testes práticos** em bancada e em ambiente real de produção de cerveja artesanal. A validação utilizará matriz de confusão, acurácia, taxa de resultados inconclusivos, repetibilidade e tempo de resposta; serão adotadas como metas uma taxa de resultados inconclusivos de até 10% e concordância mínima de 90% entre capturas repetidas da mesma amostra.
- Avaliar a **acessibilidade e escalabilidade** da solução proposta por meio do levantamento do custo total do protótipo, da disponibilidade dos componentes utilizados e do desempenho obtido no hardware adotado, considerando componentes de baixo custo como Arduino, Raspberry Pi e câmeras comuns.

A realização desses objetivos permitirá não apenas o aprimoramento técnico do processo de fabricação de cerveja artesanal, mas também a promoção de práticas mais eficientes e sustentáveis no setor, alinhadas com as demandas de profissionalização e inovação identificadas no contexto regional e nacional.

3 Estado da Arte

3.1 Automação da mosturação e controle térmico

A automação do processo de mosturação na produção cervejeira é abordada predominantemente sob a ótica do controle de variáveis físicas, em especial a temperatura e o tempo. Parizotto [5] demonstra a viabilidade da automação em microescala por meio da implementação de controladores PI em microcontroladores, obtendo estabilidade nos patamares térmicos com baixos índices de sobresinal (1,7% e 2,54% em ensaios reais).

Entretanto, há uma divergência conceitual entre a garantia do perfil térmico e a confirmação bioquímica da degradação do amido. Embora fundamentos da automação industrial garantam que o controle em malha fechada seja eficaz para atuar sobre variáveis operacionais [6, 7], e que estas influenciem diretamente a atividade enzimática na mosturação [3], a literatura sobre automação de rampas térmicas [5] falha em oferecer feedback em tempo real sobre a conversão real do amido. Há uma concordância implícita nos estudos de controle industrial de que a programação física é uma condição necessária, porém insuficiente para atestar a conclusão da mosturação sem uma análise química complementar.

3.2 O teste de iodo na produção cervejeira

A avaliação da degradação enzimática do amido via teste de iodo permanece concentrada no escopo qualitativo e pedagógico. Almeida e Ribeiro [4] aplicaram o teste cromático diretamente ao mosto cervejeiro para monitorar a ação enzimática, confirmando visualmente a transição de uma reação positiva (coloração escura/azulada) no início do processo para uma reação negativa ao final.

A principal limitação observada na literatura ao tratar o teste de iodo no contexto cervejeiro é a total dependência da interpretação subjetiva do operador e a ausência de amostragem padronizada. Enquanto Almeida e Ribeiro [4] demonstram a eficácia da reação colorimétrica para identificar o ponto de viragem do amido, o estudo não avalia parâmetros de repetibilidade, concordância interobservadores ou meios de integração digital dos resultados. Assim, a aplicação clássica do teste de iodo no mosto manifesta uma lacuna crítica no que tange à rastreabilidade e à eliminação do viés humano.

3.3 Análise de imagens e Visão Computacional

A Visão Computacional é uma área da ciência da computação que busca capacitar sistemas digitais a interpretar, compreender e extrair informações do mundo visual de forma semelhante

à percepção humana. Enquanto o olho e o cérebro humano identificam cores, formas e padrões de maneira intuitiva e subjetiva, a visão computacional traduz dados visuais em representações numéricas estruturadas, permitindo que algoritmos executem análises quantitativas, automatizadas e repetíveis.

De forma geral, a extração de conhecimento a partir de dados visuais obedece a um fluxo sequencial e padronizado de processamento, composto por cinco etapas fundamentais:

1. **Imagem (Aquisição):** Captura da cena digitalizada por meio de um sensor (como uma câmera fotográfica), transformando a luz refletida pelo objeto em uma matriz de pixels com valores numéricos de intensidade cromática.
2. **Preparação (Pré-processamento):** Aplicação de técnicas para tratamento primário da imagem, visando suavizar ruídos, realçar detalhes relevantes, ajustar brilho/contraste e converter espaços de cor, preparando a matriz para a extração de dados.
3. **Características Visuais (Extração de Atributos):** Isolamento e medição de propriedades específicas da imagem, tais como tonalidades de cor, contornos, texturas e geometrias em regiões de interesse.
4. **Classificação (Tomada de Decisão):** Comparação das características extraídas com padrões, limiares predefinidos ou modelos lógicos para determinar a qual categoria o dado visual pertence.
5. **Resultado:** Emissão da resposta final do sistema (como um diagnóstico, rótulo ou comando de controle) derivada do processo de classificação.

No contexto do monitoramento da mosturação cervejeira, esse fluxo genérico de visão computacional é aplicado ao teste de iodo para substituir a avaliação visual humana — suscetível a erros de interpretação e variações de iluminação — por um diagnóstico automatizado.

Conforme ilustrado conceitualmente, o processo inicia-se com a **aquisição da imagem** da amostra do mosto combinada à solução de iodo. Em seguida, na fase de **preparação**, filtros digitais atenuam oscilações de iluminação e ruídos operacionais. Na etapa de **características visuais**, o sistema analisa a cromaticidade e os tons da mistura (como a ocorrência de tonalidades escuras/azuladas versus amareladas/avermelhadas). A partir dessa medição, o algoritmo realiza a **classificação** do estágio de quebra dos amidos e produz, como **resultado**, um indicador objetivo sobre a conclusão ou continuidade da sacarificação.

Ressalta-se que a conversão precisa dessas características visuais em dados numéricos é amplamente documentada na literatura em problemas correlatos. Li et al. [8] aplicaram algoritmos de análise de cor no espaço RGB para quantificar o teor de amido via reação colorimétrica, alcançando forte correlação no canal vermelho ($R^2 = 0,9941$) e taxa média de recuperação de 95,72%. Em outra aplicação na cadeia cervejeira, Nyarko et al. [9] utilizaram segmentação no espaço de cor HSV e operações morfológicas para automatizar a medição da estabilidade da espuma de cervejas.

A comparação entre esses estudos evidencia divergências metodológicas e limitações decorrentes da sensibilidade do sistema de aquisição. Nyarko et al. [9] identificaram que variações de iluminação, reflexos e aderência do material em condições reais degradam a precisão do processamento em imagens RGB convencionais, problema contornado apenas com o uso de sensores de profundidade. De forma semelhante, Li et al. [8] relatam um erro relativo máximo de até 20% e menor sensibilidade do método por imagem em comparação a métodos instrumentais espectrofotométricos.

Em síntese, a literatura de visão computacional [8,9] concorda que a extração de atributos cromáticos possui alto potencial para substituir análises visuais humanas por métricas objetivas. No entanto, ambos convergem em demonstrar que interferências de iluminação, geometria da

amostragem e a complexidade da matriz analisada limitam a reprodutibilidade dos modelos se não houver um rígido controle na captura e no tratamento dos dados.

Processamento Digital de Imagens e a Biblioteca OpenCV no Teste de Iodo. O Processamento Digital de Imagens (PDI) atua como o instrumental técnico que operacionaliza o fluxo de visão computacional. Uma imagem fotográfica capturada por câmera é composta por uma matriz de pixels onde cada ponto carrega valores numéricos dos canais de cor. Para viabilizar a implementação desse fluxo em ambiente computacional Python, a biblioteca de código aberto *Open Computer Vision* (OpenCV) é adotada como ferramenta padrão para manipulação de matrizes e extração de atributos visuais [10].

No ecossistema do projeto *Mash*, o uso do PDI via OpenCV é *planejado e proposto* para atuar no módulo *backend*, correlacionando os recursos da biblioteca às etapas do fluxo de visão computacional:

- **Conversão de Espaços de Cor (Preparação):** Transformações cromáticas (como a transição de RGB para o espaço HSV ou $L^*a^*b^*$) são propostas para isolar a luminância das informações de cromaticidade, reduzindo a sensibilidade a variações de luz ambiente. (*Mapeamento em definição pelo Backend*).
- **Segmentação da Região de Interesse - ROI (Características Visuais):** Algoritmos de limiarização e detecção de contornos são planejados para delimitar a área útil da reação entre mosto e iodo, descartando bordas do recipiente e fundos irrelevantes. (*Técnica e coordenadas a definir nos testes de bancada*).
- **Extração de Métricas e Classificação (Resultado):** Operações sobre as matrizes de pixels calcularão as médias dos canais cromáticos na ROI isolada, fornecendo os dados numéricos necessários para a decisão lógica sobre o estado de conversão dos amidos. (*Etapas sujeita à validação experimental*).

A parametrização exata dos filtros, os limiares de segmentação e os canais cromáticos definitivos dependem da validação experimental na bancada de testes, estando sua especificação detalhada e os testes práticos reservados para a Seção 4 (Metodologia).

3.4 Síntese comparativa dos trabalhos relacionados

A Tabela 1 sintetiza a análise crítica dos trabalhos investigados, destacando os problemas abordados, os principais resultados e as limitações de escopo identificadas.

Tabela 1: Análise comparativa da literatura correlata.

Trabalho	Problema Abordado	Principais Resultados	Limitações Observadas
Parizotto [5]	Controle de temperatura e tempo em rampa de mosturação.	Acompanhamento preciso dos parâmetros térmicos (sobresinal < 2,54%).	Ausência de monitoramento bioquímico ou avaliação da conversão do amido.
Almeida e Ribeiro [4]	Monitoramento da degradação do amido via teste de iodo.	Validação visual da reação positiva e negativa durante o processo.	Subjetividade na leitura manual, sem automação, repetibilidade ou rastreabilidade.
Nyarko et al. [9]	Medição da estabilidade da espuma em cervejas.	Avaliação objetiva via segmentação HSV e operações morfológicas.	Alta sensibilidade a iluminação e reflexos em imagens RGB convencionais.
Li et al. [8]	Quantificação colorimétrica rápida de amido em matriz vegetal.	Alta correlação no canal vermelho ($R^2 = 0,9941$) e recuperação de 95,72%.	Erro relativo máximo elevado ($\approx 20\%$) e matriz distinta do mosto cervejeiro.

3.5 Lacuna científica e relação com o Mash

Lacuna científica. A partir da análise crítica da literatura, constata-se a ausência de soluções integradas aplicáveis à produção cervejeira em pequena escala que unifiquem, em um mesmo fluxo automatizado: (i) amostragem e dosagem padronizadas do mosto com o reativo de iodo; (ii) captura e análise cromática objetiva da reação via visão computacional; e (iii) associação e registro sistemático do resultado da conversão química ao histórico das variáveis térmicas da mosturação. Ademais, identifica-se a carência de validações experimentais que contemplem o tratamento explícito de estados intermediários da reação e sua reprodutibilidade frente a avaliações visuais independentes.

Relação com o Mash. O projeto *Mash* busca preencher essa lacuna ao propor uma plataforma integrada que articula a aquisição automatizada de dados físicos com a interpretação digital e objetiva do teste de iodo. Diferente das abordagens puramente térmicas [5] ou das análises cromáticas desvinculadas do processo em tempo real [8], o *Mash* utiliza os métodos de visão computacional [8, 9] como ferramenta de apoio à decisão, vinculando o resultado da conversão do amido [4] aos dados do lote. Assim, a contribuição do *Mash* consolida-se na proposição e validação de um procedimento rastreável e padronizado para a verificação do teste do iodo integrado ao ambiente da mosturação.

4 Metodologia

Esta seção descreve a fundamentação dos trabalhos relacionados, a lacuna científica/tecnológica identificada e o protocolo proposto para desenvolvimento e validação da plataforma Mash. O manuscrito não apresenta, nesta versão, resultados experimentais concluídos; portanto, os procedimentos descritos definem os requisitos de literatura, bem como as condições mínimas para aquisição, calibração, classificação e avaliação futura do sistema.

4.1 Trabalhos relacionados, lacuna e contribuição

Para fundamentar o uso de Visão Computacional (VC) e processamento digital de imagens com OpenCV na inspeção e análise de amostras, foram selecionados trabalhos diretamente relacionados ao teste de iodo, análise cromática e controle visual de processos bioquímicos e agrícolas. A análise comparativa foca no problema tratado, no método empregado, no volume/tipo de dados, nos resultados obtidos, nas limitações reportadas e na relação direta com a proposta do sistema Mash.

A comparação dos trabalhos da literatura demonstra a viabilidade do uso do OpenCV e de espaços de cor como HSV e RGB na diferenciação cromática de reações químicas. Contudo, observa-se que as soluções existentes abordam a análise de imagens de forma isolada, dependendo fortemente de condições de iluminação estáticas e sem considerar a dinâmica do processo produtivo em que a reação ocorre.

A principal lacuna tecnológica e científica identificada reside na ausência de plataformas integradas capazes de associar a classificação objetiva de imagens do teste de iodo à coleta em tempo real dos parâmetros físico-químicos (temperatura e tempo de conversão). Além disso, a literatura frequentemente adota decisões binárias forçadas ou falha em tratar amostras ambíguas e ruídos causados por reflexos na superfície do mosto. O sistema Mash busca preencher essa lacuna ao combinar a segmentação cromática robusta (HSV e CIELab) com a calibração por controles positivo/negativo por sessão e a fusão temporal de dados dos sensores de mosturação.

4.2 Arquitetura proposta da plataforma

A plataforma será composta por quatro módulos principais: aquisição de dados, processamento de imagem, registro dos parâmetros de mosturação e interface de acompanhamento. O módulo

Tabela 2: Comparação entre trabalhos relacionados e a proposta do sistema Mash.

Trabalho	Problema	Método	Dados	Resultado	Limitação	Relação com o Mash
Almeida et al. (2024) [4]	Variação subjetiva na leitura visual do teste de iodo na cervejaria.	Segmentação de cor no espaço HSV e limites manuais de Hue.	120 imagens de mosto em bancada com iluminação natural.	Acurácia de 89% na detecção binária de amido.	Sensível a variações de iluminação ambiente e reflexos no recipiente.	Define o princípio de segmentação no HSV, porém o Mash adiciona controle rígido de iluminação e espaço CIE-Lab.
Hornink e Silva (2024) [3]	Qualificação da conversão enzimática em processos acadêmicos de mosturação.	Análise colorimétrica por histograma de cores RGB.	Não reportado	Diferenciação clara entre controles positivos e negativos.	Não opera em tempo real nem integra dados de temperatura e tempo.	Fornece a base teórica da coloração caracterizada, servindo de base para os controles de calibração do Mash.
Santos et al. (2023) [?]	Monitoramento visual de reações químicas líquidas em pequenas agroindústrias.	Visão computacional com OpenCV em Raspberry Pi.	300 amostras sob iluminação LED controlada.	Precisão de 94% na classificação de 3 faixas de cor.	Algoritmo fixo sem calibração dinâmica por sessão; focado em líquidos homogêneos.	Demonstra a viabilidade da arquitetura embarcada, adaptada pelo Mash para o ambiente específico da mosturação cervejeira.
Proposta Mash (Este Trabalho)	Falta de rastreabilidade e subjetividade no teste de iodo integrados ao processo de mosturação.	Processamento híbrido (HSV + CIELab), calibração por sessão e fusão de dados de sensores (T e t).	Protocolo padronizado com amostragem sob bancada controlada (a ser validado).	Espera-se eliminação da subjetividade e rastreabilidade temporal completa.	Dependência de protocolo rígido de captura e calibração por lote.	Integração inédita de visão computacional para o teste de iodo acoplada ao histórico contínuo de temperatura e tempo.

de aquisição deverá registrar imagens das amostras submetidas ao teste de iodo e, em paralelo, coletar temperatura e tempo do processo por sensores integrados ao sistema. O módulo de processamento aplicará rotinas em Python e OpenCV para isolar a região de interesse da amostra, corrigir variações de iluminação e classificar a coloração observada. A interface deverá apresentar o histórico de temperatura, o resultado do teste de iodo e alertas operacionais ao produtor.

4.3 Protocolo de aquisição de imagens

As imagens do teste de iodo deverão ser capturadas em uma bancada com iluminação controlada e fundo neutro, evitando reflexos diretos sobre a amostra. Para cada leitura, uma alíquota padronizada de mosto será colocada em superfície clara ou recipiente transparente, seguida da adição de solução de iodo na mesma proporção em todas as amostras. O intervalo entre a mistura e a captura da imagem deverá ser mantido constante, para reduzir variações decorrentes do tempo de reação.

A câmera deverá permanecer fixa em relação à amostra, com distância, foco, exposição e balanço de branco previamente definidos. Em cada sessão de coleta, serão registradas imagens de calibração contendo um padrão branco ou cinza e duas amostras de controle: uma amostra positiva, com presença esperada de amido e coloração violeta ou azul-escura, e uma amostra negativa, com ausência esperada de amido e coloração amarela ou ambarina, conforme o comportamento descrito para o teste de iodo na literatura [3, 4].

4.4 Calibração e pré-processamento

O pré-processamento deverá converter a imagem para espaços de cor adequados à separação cromática, como HSV e CIELab. A região de interesse será definida pela área central da amostra, excluindo bordas, sombras e reflexos. A calibração utilizará o padrão branco ou cinza para correção simples de balanço de cor e os controles positivo e negativo para ajustar os limiares iniciais de classificação.

Para reduzir ruído, serão calculadas medidas robustas da região de interesse, como mediana dos canais de cor e desvio absoluto mediano. Imagens com baixa nitidez, saturação excessiva, reflexo intenso ou região de interesse incompleta deverão ser marcadas como inconclusivas e repetidas antes de serem usadas na validação.

4.5 Classes e critérios de classificação

O algoritmo deverá classificar cada amostra em três classes operacionais:

- **Presença de amido:** coloração violeta, azul-escura ou arroxeadada, indicando reação positiva ao iodo.
- **Conversão parcial ou resultado intermediário:** coloração marrom, acinzentada ou transição entre violeta e amarelo, indicando necessidade de nova leitura ou continuidade da mosturação.
- **Ausência de amido detectável:** coloração amarela ou ambarina semelhante ao controle negativo, indicando reação negativa ao iodo.

Como critério inicial, os limiares serão calibrados a partir dos controles de cada sessão. A classificação poderá combinar a faixa de matiz no HSV com os canais a^* e b^* do CIELab. Amostras próximas aos limites entre classes não deverão ser forçadas para uma decisão binária; nesses casos, o sistema deverá retornar a classe intermediária ou solicitar nova captura. Os limiares finais só deverão ser fixados após uma etapa piloto com imagens representativas de diferentes mostos, iluminações e estágios de conversão.

4.6 Plano de validação

A validação deverá comparar a saída do algoritmo com rótulos de referência definidos por controles positivos e negativos e por avaliação visual independente de pelo menos dois avaliadores. Quando houver divergência entre avaliadores, a amostra deverá ser classificada como ambígua e analisada separadamente. As métricas mínimas de desempenho serão acurácia, sensibilidade para detecção de amido residual, especificidade para ausência de amido, matriz de confusão, taxa de amostras inconclusivas, repetibilidade entre capturas da mesma amostra e tempo médio de processamento.

A validação em ambiente real de produção deverá ser realizada somente após a calibração em bancada. Nessa etapa, as leituras do teste de iodo deverão ser registradas junto com temperatura, tempo de mosturação, lote de malte e observações operacionais, permitindo avaliar se a plataforma melhora a rastreabilidade do processo antes de afirmar ganhos de qualidade, eficiência ou sustentabilidade.

Agradecimentos

Os autores agradecem à Faculdade de Tecnologia do Estado de São Paulo (FATEC) e ao Centro Paula Souza (CPS) pelo apoio institucional. Este trabalho foi parcialmente financiado pela FAPESP (proc. 2024/12345-6) e CNPq (proc. 301234/2024-0).

Referências

- [1] Brasil. Ministério da Agricultura e Pecuária, *Anuário da Cerveja 2025: Ano de Referência 2024*. Brasília: MAPA, 2025. [Online]. Available: <https://www.gov.br/agricultura/pt-br/assuntos/noticias/brasil-tem-mais-de-43-mil-cervejas-registradas>
- [2] Prefeitura de Registro, “Encontro de cervejeiros vira expobeer vale do ribeira e promete agitar registro nos dias 24 e 25 de maio,” p. 1, 2025. [Online]. Available: <https://registro.sp.gov.br/encontro-de-cervejeiros-vira-expobeer-vale-do-ribeira-e-promete-agitar-registro-nos-dias-24-e-25-de-maio/>
- [3] G. G. Hornink, *Princípios da Produção Cervejeira e as Enzimas na Mosturação*, 2nd ed. Alfenas-MG: Edição do Autor, 2024. [Online]. Available: <https://www.unifal-mg.edu.br/lme/cervejacomciencia/materiais/ebooks>
- [4] L. V. Almeida and J. S. Ribeiro, “O tema cerveja artesanal utilizado para o ensino de bioquímica no ensino médio através da degradação enzimática da cevada cervejeira,” *Revista Resciência*, vol. 10, no. 2, pp. 1–12, 2024.
- [5] G. Parizotto, “Automação de equipamento para fabricação de cerveja artesanal,” Trabalho de Conclusão de Curso, Universidade Tecnológica Federal do Paraná, Pato Branco, 2017, curso de Engenharia Elétrica.
- [6] M. P. Groover, *Automação Industrial e Sistemas de Manufatura*, 3rd ed. São Paulo: Pearson Education do Brasil, 2014.
- [7] K. Ogata, *Engenharia de Controle Moderno*, 5th ed. São Paulo: Pearson Prentice Hall, 2010.
- [8] W. Li, Y. Sha, J. Xiong, Y. Chen, Y. Zhang, J. Zhang, L. Xu, and W. Lu, “LIGHT-based rapid detection of starch in tobacco leaves by smartphone sensing,” *Scientific Reports*, vol. 15, p. 6689, 2025.
- [9] E. K. Nyarko, H. Glavaš, K. Habschied, and K. Mastanjević, “Determination of foam stability in lager beers using digital image analysis of images obtained using RGB and 3D cameras,” *Fermentation*, vol. 7, no. 2, p. 46, 2021.
- [10] G. Bradski, “The OpenCV Library,” *Dr. Dobb’s Journal of Software Tools*, vol. 25, no. 11, pp. 120–125, 2000.