

Plataforma de Monitoramento da Etapa de Mosturação na Fabricação de Cerveja Artesanal

Haimon Cugler Vieira¹, João Alexandre Pinto Camargo²,
Jocieli Pontes Domingues da Silva³, Kevin da Silva Oliveira⁴

¹ Faculdade de Tecnologia do Estado de São Paulo

² Faculdade de Tecnologia do Estado de São Paulo

³ Faculdade de Tecnologia do Estado de São Paulo

⁴ Faculdade de Tecnologia do Estado de São Paulo

haimon.vieira@aluno.cps.sp.gov.br, joao.camargo10@aluno.cps.sp.gov.br

jocieli.domingues@aluno.cps.sp.gov.br, kevin.oliveira6@aluno.cps.sp.gov.br

1 Introdução

O setor cervejeiro brasileiro tem experimentado crescimento consistente nos últimos anos. De acordo com o *Anuário da Cerveja 2025: Ano de Referência 2024*, o Brasil registrou 1.949 cervejarias em funcionamento, com crescimento de 5,5% em relação ao ano anterior, sendo a região Sudeste responsável por 45,6% desses estabelecimentos [1]. Esse cenário evidencia a expansão do mercado cervejeiro nacional.

No contexto regional, a EXPOBEER Vale do Ribeira evoluiu do tradicional Encontro de Cervejeiros e passou a integrar ações de capacitação técnica, rodadas de negócios e valorização da produção local [2]. Esse ambiente de articulação regional motiva a investigação de tecnologias acessíveis para o acompanhamento das etapas críticas da fabricação.

Contudo, a produção em pequena escala pode apresentar limitações de automação e de registro das variáveis do processo. Essa dificuldade é particularmente relevante na mosturação, etapa em que o acompanhamento da temperatura e do tempo precisa ser relacionado ao avanço da conversão do amido, e não apenas ao cumprimento de uma programação térmica.

A mosturação consiste no aquecimento controlado da mistura de água e malte para favorecer a ação das enzimas responsáveis pela degradação do amido e pela formação de açúcares fermentescíveis e dextrinas. Temperatura, tempo e pH influenciam essa atividade enzimática e, consequentemente, as características do mosto produzido [3]. O monitoramento da temperatura indica se as condições programadas foram mantidas, mas não determina, isoladamente, se ainda existe amido residual na amostra.

O teste de iodo é utilizado para acompanhar essa conversão. Nele, uma alíquota do mosto entra em contato com uma solução contendo iodo, produzindo tons escuros, violetas ou avermelhados quando ainda existem estruturas amiláceas capazes de reagir com o composto e uma coloração amarela quando essas estruturas já não são detectadas pelo teste [3]. Almeida e Ribeiro aplicaram esse procedimento no início e ao final de uma mosturação, interpretando visualmente a mudança de coloração [4].

Quando realizada manualmente, essa interpretação depende da comparação visual feita pelo operador e pode ser dificultada por gradações intermediárias, iluminação, reflexos e características da própria amostra. Além disso, se a imagem e o resultado do teste não forem registrados juntamente com data, hora, temperatura e tempo de mosturação, torna-se difícil revisar a decisão tomada e comparar leituras entre diferentes lotes. O problema investigado neste trabalho é,

portanto, como tornar a leitura do teste de iodo mais padronizada e rastreável, sem apresentar a automação proposta como substituta de uma análise laboratorial quantitativa.

Em relação aos Objetivos de Desenvolvimento Sustentável (ODS) das Nações Unidas [5], a proposta relaciona-se ao ODS 9 (Indústria, Inovação e Infraestrutura) por investigar uma alternativa de automação para pequenos produtores. Uma eventual contribuição ao ODS 12 (Consumo e Produção Responsáveis) dependerá de estudos posteriores que demonstrem redução de desperdícios ou melhoria de rendimento. Nesta versão, esses efeitos não foram avaliados experimentalmente.

2 Objetivos

O objetivo geral deste trabalho é desenvolver uma plataforma de monitoramento para a fabricação de cerveja artesanal, utilizando visão computacional com Python e OpenCV para automatizar a interpretação do teste de iodo. A plataforma deverá adquirir, apresentar e analisar dados da mosturação, permitindo avaliar seu potencial para apoiar a rastreabilidade e o controle operacional.

Os objetivos específicos deste trabalho são:

- Desenvolver um sistema para a interpretação automatizada do **teste de iodo** utilizando **visão computacional com Python e OpenCV**, capaz de detectar a presença de amido residual no mosto. A acurácia será calculada somente entre as classificações conclusivas, isto é, após excluir os resultados marcados como inconclusivos, cuja taxa será informada separadamente. A meta numérica de acurácia será definida após o estudo piloto.
- Implementar um algoritmo de processamento de imagem para **análise da cor da reação de iodo**, diferenciando automaticamente as classes presença de amido, conversão parcial e ausência de amido detectável, e integrar essa análise ao monitoramento de temperatura. O tempo de resposta, medido entre o envio da imagem e a exibição do resultado, deverá apresentar média de até 2 segundos no hardware adotado. A métrica percentilica complementar e seu respectivo limite serão definidos após a caracterização do protótipo.
- Desenvolver uma interface de usuário que permita a **visualização e análise dos dados** coletados, incluindo gráficos de temperatura, resultados do teste de iodo e alertas para ajustes necessários no processo de mosturação. Como indicadores, será verificado o registro de 100% das leituras válidas com data e hora, temperatura, classificação e tempo de resposta, bem como a emissão de alerta nos casos previstos pelas regras do sistema. O registro integral das leituras válidas foi adotado como requisito para preservar a rastreabilidade do lote.
- Validar a plataforma desenvolvida por meio de **testes práticos** em bancada e em ambiente real de produção de cerveja artesanal. A validação utilizará matriz de confusão, acurácia, taxa de resultados inconclusivos, repetibilidade e tempo de resposta; serão adotadas como metas uma taxa de resultados inconclusivos de até 10% e concordância mínima de 90% entre capturas repetidas da mesma amostra. A primeira meta limita a necessidade de novas capturas para preservar a utilidade operacional do sistema, enquanto a segunda avalia a estabilidade da classificação diante da repetição da captura. Ambas deverão ser reavaliadas após o estudo piloto.
- Avaliar a **acessibilidade e escalabilidade** da solução proposta por meio do levantamento do custo total do protótipo, da disponibilidade dos componentes utilizados e do desempenho obtido no hardware adotado, considerando componentes de baixo custo como Arduino, Raspberry Pi e câmeras comuns.

A realização desses objetivos permitirá avaliar a aplicabilidade técnica da plataforma no processo de fabricação de cerveja artesanal e produzir evidências sobre sua contribuição para a rastreabilidade e o controle da mosturação.

3 Estado da Arte

3.1 Automação da mosturação e controle térmico

A automação do processo de mosturação na produção cervejeira é abordada predominantemente sob a ótica do controle de variáveis físicas, em especial a temperatura e o tempo. Parizotto [6] demonstra a viabilidade da automação em microescala por meio da implementação de controladores PI em microcontroladores, obtendo estabilidade nos patamares térmicos com baixos índices de sobresinal (1,7% e 2,54% em ensaios reais).

Entretanto, há uma divergência conceitual entre a garantia do perfil térmico e a confirmação bioquímica da degradação do amido. Os fundamentos da automação industrial descrevem o controle em malha fechada como meio de atuar sobre variáveis operacionais [7, 8], enquanto temperatura, tempo e pH influenciam diretamente a atividade enzimática na mosturação [3]. Contudo, o sistema de automação de rampas térmicas apresentado por Parizotto [6] não contempla feedback em tempo real sobre a conversão do amido. Assim, o cumprimento da programação térmica não é suficiente, isoladamente, para atestar a conclusão da mosturação.

3.2 O teste de iodo na produção cervejeira

A avaliação da degradação enzimática do amido via teste de iodo permanece concentrada no escopo qualitativo e pedagógico. Almeida e Ribeiro [4] aplicaram o teste cromático diretamente ao mosto cervejeiro para monitorar a ação enzimática, confirmando visualmente a transição de uma reação positiva (coloração escura/azulada) no início do processo para uma reação negativa ao final.

A principal limitação observada na literatura ao tratar o teste de iodo no contexto cervejeiro é a dependência da interpretação visual do operador e a ausência de amostragem padronizada. Almeida e Ribeiro [4] ilustram visualmente a diferença entre uma reação positiva no início e uma reação negativa ao final da mosturação, mas o estudo não avalia parâmetros de repetibilidade, concordância interobservadores ou meios de integração digital dos resultados. Assim, a aplicação manual do teste de iodo apresenta limitações de rastreabilidade e de padronização da leitura.

3.3 Análise de imagens e visão computacional

A visão computacional reúne métodos para adquirir, processar e extrair informações de imagens digitais. Nessa abordagem, propriedades como cor, forma e textura são representadas numericamente, permitindo análises automatizadas e repetíveis [9, 10].

Neste trabalho, o fluxo de processamento é organizado em cinco etapas:

1. **Imagem (Aquisição):** Captura da cena digitalizada por meio de um sensor (como uma câmera fotográfica), transformando a luz refletida pelo objeto em uma matriz de pixels com valores numéricos de intensidade cromática.
2. **Preparação (Pré-processamento):** Aplicação de técnicas para tratamento primário da imagem, visando suavizar ruídos, realçar detalhes relevantes, ajustar brilho/contraste e converter espaços de cor, preparando a matriz para a extração de dados.
3. **Características Visuais (Extração de Atributos):** Isolamento e medição de propriedades específicas da imagem, tais como tonalidades de cor, contornos, texturas e geometrias em regiões de interesse.

4. **Classificação (Tomada de Decisão):** Comparação das características extraídas com padrões, limiares predefinidos ou modelos lógicos para determinar a qual categoria o dado visual pertence.
5. **Resultado:** Emissão da resposta final do sistema (como um diagnóstico, rótulo ou comando de controle) derivada do processo de classificação.

No monitoramento da mosturação, esse fluxo é aplicado ao teste de iodo para apoiar a avaliação visual por meio de uma classificação automatizada e rastreável. A proposta não substitui uma análise laboratorial quantitativa.

O processo proposto inicia-se com a **aquisição da imagem** da amostra de mosto combinada à solução de iodo. Na fase de **preparação**, filtros digitais deverão atenuar oscilações de iluminação e ruídos operacionais. Na etapa de **extração de características**, serão calculadas medidas cromáticas da região de interesse. Por fim, o algoritmo deverá **classificar** a amostra e registrar o resultado com os dados do processo.

Ressalta-se que a conversão dessas características visuais em dados numéricos é documentada na literatura em problemas correlatos. Li et al. [11] aplicaram algoritmos de análise de cor no espaço RGB para quantificar o teor de amido por meio de reação colorimétrica com antrona e ácido sulfúrico, alcançando forte correlação no canal vermelho ($R^2 = 0,9941$) e taxa média de recuperação de 95,72%. Em outra aplicação na cadeia cervejeira, Nyarko et al. [12] utilizaram segmentação no espaço de cor HSV e operações morfológicas para automatizar a medição da estabilidade da espuma de cervejas.

A comparação entre esses estudos evidencia divergências metodológicas e limitações decorrentes do sistema de aquisição. Nyarko et al. [12] relatam dificuldades associadas a reflexos de luz no vidro, ao autofoco e à aderência da espuma às paredes do recipiente nas imagens RGB, limitações reduzidas com o emprego de uma câmera 3D. Li et al. [11] relatam erro relativo médio de 3,83% entre condições distintas de iluminação, evidenciando a necessidade de controlar ou compensar esse fator durante a aquisição por smartphone.

Em síntese, os estudos de Nyarko et al. e Li et al. [11,12] demonstram a viabilidade da extração de atributos cromáticos, mas também evidenciam a influência da iluminação, da geometria de aquisição e da matriz analisada. Esses fatores justificam o controle das condições de captura e a calibração do sistema.

Processamento digital de imagens e OpenCV no teste de iodo. O Processamento Digital de Imagens (PDI) atua como o instrumental técnico que operacionaliza o fluxo de visão computacional. Uma imagem fotográfica capturada por câmera é composta por uma matriz de pixels onde cada ponto carrega valores numéricos dos canais de cor. Para viabilizar a implementação desse fluxo em ambiente computacional Python, a biblioteca de código aberto *Open Computer Vision* (OpenCV) é adotada como ferramenta padrão para manipulação de matrizes e extração de atributos visuais [13].

No projeto *Mash*, o processamento com OpenCV deverá contemplar as seguintes operações:

- **Conversão de espaços de cor:** transformação da imagem para HSV e CIELAB, a fim de separar informações de luminância e cromaticidade [14].
- **Segmentação da região de interesse:** delimitação da área útil da reação, com exclusão de bordas, fundo, sombras e reflexos.
- **Extração de atributos e classificação:** cálculo de medidas robustas dos canais cromáticos e comparação com os controles da sessão.

A parametrização dos filtros, os limiares de segmentação e os canais cromáticos definitivos dependerão da calibração experimental descrita na Seção 4.

3.4 Síntese comparativa dos trabalhos relacionados

A Tabela 1 sintetiza a análise crítica dos trabalhos investigados, destacando os problemas abordados, os principais resultados e as limitações de escopo identificadas.

Tabela 1: Análise comparativa da literatura correlata.

Trabalho	Problema Abordado	Principais Resultados	Limitações Observadas
Parizotto [6]	Controle de temperatura e tempo em rampa de mosturação.	Acompanhamento dos patamares térmicos, com sobresinal máximo de 2,54%.	Ausência de monitoramento bioquímico ou avaliação da conversão do amido.
Almeida e Ribeiro [4]	Monitoramento da degradação do amido via teste de iodo.	Observação visual da reação positiva no início e negativa ao final do processo.	Leitura manual, sem avaliação de repetibilidade ou rastreabilidade digital.
Nyarko et al. [12]	Medição da estabilidade da espuma em cervejas.	Avaliação objetiva via segmentação HSV e operações morfológicas.	Reflexos no vidro, autofoco e aderência da espuma limitam as imagens RGB convencionais.
Li et al. [11]	Quantificação colorimétrica rápida de amido em matriz vegetal.	Alta correlação no canal vermelho ($R^2 = 0,9941$) e recuperação média de 95,72%.	Erro relativo médio de 3,83% entre condições de iluminação distintas e matriz diferente do mosto cervejeiro.

3.5 Lacuna científica

No conjunto de trabalhos analisados, não foi identificada uma solução voltada à produção cervejeira em pequena escala que associe a aquisição padronizada de imagens do teste de iodo, o tratamento explícito de resultados intermediários e o registro da classificação junto ao histórico de temperatura e tempo da mosturação. O projeto *Mash* propõe integrar esses elementos em um procedimento rastreável, cuja validade e reprodutibilidade ainda deverão ser avaliadas experimentalmente.

4 Metodologia

Esta seção descreve o protocolo proposto para desenvolvimento e validação da plataforma Mash. O manuscrito não apresenta, nesta versão, resultados experimentais concluídos; portanto, os procedimentos descritos estabelecem as condições mínimas para aquisição, calibração, classificação e avaliação futura do sistema.

4.1 Trabalhos relacionados e contribuição metodológica

Os trabalhos relacionados foram utilizados para derivar requisitos verificáveis para o protocolo. A Tabela 2 apresenta a relação entre as evidências da literatura e as decisões metodológicas do projeto.

Tabela 2: Requisitos metodológicos derivados da literatura.

Fonte	Evidência utilizada	Requisito adotado no projeto
Almeida e Ribeiro [4]	Teste de iodo aplicado visualmente no início e no fim da mosturação.	Registrar imagens e utilizar referências positiva e negativa em cada sessão.
Hornink [3]	Relação entre a degradação do amido e a sequência de cores do teste de iodo.	Definir classes cromáticas coerentes com a reação e tratar estados intermediários.
Li et al. [11]	Influência da iluminação na quantificação colorimétrica por smartphone.	Controlar a iluminação e realizar calibração cromática por sessão.
Nyarko et al. [12]	Uso de HSV e operações morfológicas, com limitações decorrentes de reflexos e geometria de captura.	Delimitar a região de interesse e aplicar critérios de qualidade antes da classificação.

A contribuição metodológica consiste na integração desses requisitos ao registro de temperatura e tempo da mosturação. As subseções seguintes descrevem como a integração deverá ser implementada e avaliada.

4.2 Arquitetura proposta da plataforma

A plataforma será composta por quatro módulos: aquisição de imagens e dados, processamento de imagem, registro dos parâmetros da mosturação e interface de acompanhamento. O primeiro módulo deverá registrar as imagens do teste de iodo e coletar temperatura e tempo do processo. O módulo de processamento aplicará rotinas em Python e OpenCV para verificar a qualidade da imagem, isolar a região de interesse, extrair atributos cromáticos e classificar a amostra. A interface deverá apresentar o histórico de temperatura, os resultados do teste e os alertas previstos pelas regras do sistema.




Figura 1: Fluxograma operacional da plataforma Mash, distinguindo os módulos implementados e planejados.

4.3 Protocolo de aquisição de imagens

As imagens do teste de iodo deverão ser capturadas em uma bancada com iluminação controlada e fundo neutro. A disposição da fonte luminosa deverá minimizar sombras e reflexos diretos sobre

a amostra.

Para cada leitura, será utilizada uma alíquota padronizada de mosto, depositada em um suporte de coleta mantido constante durante o experimento. A solução de iodo deverá ser adicionada em proporção constante em relação ao volume da alíquota.

O intervalo entre a mistura do mosto com a solução de iodo e a captura da imagem deverá ser igual em todas as leituras, reduzindo variações associadas ao tempo de reação.

A câmera deverá permanecer fixa em relação à amostra. Distância, enquadramento, foco, exposição e balanço de branco deverão ser definidos antes do início da coleta e mantidos durante toda a sessão.

Em cada sessão, serão registradas imagens de calibração com um padrão branco ou cinza, um controle positivo com presença esperada de amido e coloração violeta ou azul-escuro e um controle negativo com ausência esperada de amido e coloração amarela ou ambarina, conforme o comportamento descrito para o teste de iodo [3,4]. Cada registro deverá conter identificador da amostra, lote, sessão, data, hora, temperatura e tempo de mosturação.

Os valores do volume da alíquota, da proporção de iodo, do intervalo entre mistura e captura, da distância da câmera e das condições de iluminação serão definidos no estudo piloto e incorporados ao protocolo final.

4.4 Calibração e pré-processamento

O pré-processamento deverá converter a imagem para os espaços de cor HSV e CIELAB [14]. A região de interesse será definida pela área central da amostra, excluindo bordas, sombras e reflexos. A calibração utilizará o padrão branco ou cinza para correção do balanço de cor e os controles positivo e negativo para ajustar os limiares iniciais de classificação.

Para reduzir ruído, serão calculadas medidas robustas da região de interesse, como mediana dos canais de cor e desvio absoluto mediano. Imagens com baixa nitidez, saturação excessiva, reflexo intenso ou região de interesse incompleta deverão ser marcadas como inconclusivas e repetidas antes de serem usadas na validação.

4.5 Classes e critérios de classificação

O algoritmo deverá classificar cada amostra em três classes operacionais:

- **Presença de amido:** coloração violeta, azul-escuro ou arroxeada, indicando reação positiva ao iodo.
- **Conversão parcial:** tonalidade intermediária entre os controles positivo e negativo, indicando presença de estruturas amiláceas em processo de degradação.
- **Ausência de amido detectável:** coloração amarela ou ambarina semelhante ao controle negativo, indicando reação negativa ao iodo.

Como critério inicial, os limiares serão calibrados a partir dos controles de cada sessão. A classificação poderá combinar a faixa de matiz no HSV com os canais a^* e b^* do espaço CIELAB, e as amostras cromaticamente próximas aos limites deverão ser classificadas como conversão parcial. O termo *inconclusivo* será reservado às imagens que não atenderem aos critérios de qualidade, como nitidez, exposição e integridade da região de interesse. Os limiares finais somente serão fixados após o estudo piloto.

4.6 Plano de validação

A validação deverá comparar a saída do algoritmo com rótulos de referência definidos pelos controles e pela avaliação visual independente de pelo menos dois avaliadores. A concordância

entre avaliadores deverá ser registrada; divergências serão tratadas por consenso ou mantidas como amostras ambíguas em uma análise separada.

As imagens usadas para ajustar limiares no estudo piloto não deverão compor o conjunto principal de validação. O número de amostras, o número de capturas repetidas e a divisão entre os conjuntos de calibração e validação deverão ser definidos antes da coleta definitiva.

As métricas mínimas serão matriz de confusão, acurácia entre classificações conclusivas, precisão, sensibilidade e medida F1 por classe, taxa de imagens inconclusivas, repetibilidade entre capturas e tempo de processamento. Sempre que o tamanho da amostra permitir, as estimativas deverão ser acompanhadas por intervalos de confiança.

A validação em ambiente real de produção deverá ser realizada somente após a calibração em bancada. Nessa etapa, as leituras do teste de iodo deverão ser registradas junto com temperatura, tempo de mosturação, lote de malte e observações operacionais, permitindo avaliar se a plataforma melhora a rastreabilidade do processo antes de afirmar ganhos de qualidade, eficiência ou sustentabilidade.

Agradecimentos

Os autores agradecem à Faculdade de Tecnologia do Estado de São Paulo (FATEC) e ao Centro Paula Souza (CPS) pelo apoio institucional. Este trabalho foi parcialmente financiado pela FAPESP (proc. 2024/12345-6) e CNPq (proc. 301234/2024-0).

Referências

- [1] Brasil. Ministério da Agricultura e Pecuária, *Anuário da Cerveja 2025: Ano de Referência 2024*. Brasília: MAPA, 2025. [Online]. Available: <https://repositorio-dspace.agricultura.gov.br/handle/1/6055>
- [2] Prefeitura de Registro, “Encontro de cervejeiros vira expobeer vale do ribeira e promete agitar registro nos dias 24 e 25 de maio,” 2025. [Online]. Available: <https://registro.sp.gov.br/encontro-de-cervejeiros-vira-expobeer-vale-do-ribeira-e-promete-agitar-registro-nos-dias-24-e-25-de-maio/>
- [3] G. G. Hornink, *Princípios da Produção Cervejeira e as Enzimas na Mosturação*, 2nd ed. Alfenas-MG: Edição do Autor, 2024. [Online]. Available: <https://www.unifal-mg.edu.br/lme/cervejacomciencia/materiais/ebooks>
- [4] L. V. Almeida and J. S. Ribeiro, “O tema cerveja artesanal utilizado para o ensino de bioquímica no ensino médio através da degradação enzimática da cevada cervejeira,” *Revista Ifes Ciência*, vol. 10, no. 2, pp. 1–11, 2024.
- [5] United Nations, “The 17 goals: Sustainable development goals,” 2015. [Online]. Available: <https://sdgs.un.org/goals>
- [6] G. Parizotto, “Automação de equipamento para fabricação de cerveja artesanal,” Trabalho de Conclusão de Curso, Universidade Tecnológica Federal do Paraná, Pato Branco, 2017, curso de Engenharia Elétrica.
- [7] M. P. Groover, *Automação Industrial e Sistemas de Manufatura*, 3rd ed. São Paulo: Pearson Prentice Hall, 2011.
- [8] K. Ogata, *Engenharia de Controle Moderno*, 5th ed. São Paulo: Pearson Prentice Hall, 2011.

- [9] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 4th ed. New York: Pearson, 2018.
- [10] R. Szeliski, *Computer Vision: Algorithms and Applications*, 2nd ed. Cham: Springer, 2022.
- [11] W. Li, Y. Sha, J. Xiong, Y. Chen, Y. Zhang, J. Zhang, L. Xu, and W. Lu, “LIGHt-based rapid detection of starch in tobacco leaves by smartphone sensing,” *Scientific Reports*, vol. 15, p. 6689, 2025.
- [12] E. K. Nyarko, H. Glavaš, K. Habschied, and K. Mastanjević, “Determination of foam stability in lager beers using digital image analysis of images obtained using RGB and 3D cameras,” *Fermentation*, vol. 7, no. 2, p. 46, 2021.
- [13] G. Bradski, “The OpenCV Library,” *Dr. Dobb’s Journal of Software Tools*, vol. 25, no. 11, pp. 120–125, 2000.
- [14] OpenCV Team, “OpenCV documentation: Image processing and color space conversions,” 2026. [Online]. Available: https://docs.opencv.org/4.x/d7/da8/tutorial_table_of_content_imgproc.html